

# OmniVoice / VozPro

## Documentacao de Infraestrutura e Migracao

---

Oracle Cloud: 147.15.77.137

Data: 02/06/2026

Migracao: Gradio API -> native-generate

# 1. Visao Geral da Infraestrutura

O sistema OmniVoice/VozPro opera em uma arquitetura distribuida entre tres maquinas: o servidor Oracle Cloud (147.15.77.137), que hospeda o PHP backend e o frontend Next.js; a maquina local do usuario com GPU RTX 3060, que executa o modelo OmniVoice e gera audio; e o servico de tunnel Cloudflare, que conecta os dois securely. A comunicacao entre o Oracle e a GPU local e feita exclusivamente via tunnel criptografado, eliminando a necessidade de portas abertas no firewall da rede local.

## 1.1 Componentes Ativos

| Componente           | Localizacao                    | Funcao                                    |
|----------------------|--------------------------------|-------------------------------------------|
| Nginx + PHP-FPM      | Oracle (147.15.77.137)         | Serve API PHP + proxy reverso pro Next.js |
| Next.js (standalone) | Oracle /home/ubuntu/omnivoice/ | Frontend web do VozPro (PM2)              |
| OmniVoice GPU        | Maquina local (RTX 3060)       | Modelo TTS OmniVoice via Python           |
| Cloudflare Tunnel    | Maquina local                  | Expoe GPU local na internet               |
| PostgreSQL           | Oracle localhost:5432          | Banco de dados do VozPro                  |

Tabela 1: Componentes ativos do sistema

## 1.2 Dominios e Sub-dominios

O sistema utiliza multiplos dominios, todos configurados no Nginx do servidor Oracle. Cada dominio aponta para um componente especifico da infraestrutura. O dominio principal do produto e vozprooff.com.br, enquanto os sub-dominios cvmnews.com.br sao usados para a API e o frontend.

| Dominio               | Proxy Para                | Tipo           | SSL         |
|-----------------------|---------------------------|----------------|-------------|
| api.cvmnews.com.br    | /var/www/omnivoice/ (PHP) | PHP-FPM direto | Let Encrypt |
| api.sorteiomax.com.br | /var/www/omnivoice/ (PHP) | PHP-FPM direto | Let Encrypt |
| vozpro.cvmnews.com.br | 127.0.0.1:3001 (Next.js)  | Reverse proxy  | Let Encrypt |
| vozprooff.com.br      | 127.0.0.1:3001 (Next.js)  | Reverse proxy  | Let Encrypt |

Tabela 2: Mapeamento de dominios no Nginx

## 1.3 Apps no PM2

O gerenciador de processos PM2 controla os serviços Node.js no Oracle. Atualmente, dois processos estão ativos: o omnivoice (frontend VozPro) e o osfy (aplicativo separado). O PM2 garante restart automático em caso de falha e gerencia os logs de cada processo.

| PM2 ID | Nome      | Script                                            | Porta | Status |
|--------|-----------|---------------------------------------------------|-------|--------|
| 0      | omnivoice | /home/ubuntu/omnivoice/.next/standalone/server.js | 3001  | online |
| 1      | osfy      | cluster mode                                      | 3000  | online |

Tabela 3: Processos PM2 ativos

## 1.4 vozpro-app (Deployment Antigo)

Existe um diretório /var/www/vozpro-app/ no Oracle que representa um deployment antigo do VozPro. Este deployment NAO está ativo no PM2 e NAO está sendo servido pelo Nginx para nenhum domínio. O diretório contém um arquivo ecosystem.config.js que referencia port 3001 e um build .next, porém o PM2 não está rodando este processo.

O sub-domínio vozpro.cvmnews.com.br, que anteriormente poderia ter apontado para este deployment, agora faz proxy para 127.0.0.1:3001, que é o processo omnivoice (deploy atual em /home/ubuntu/omnivoice/). Ou seja, o vozpro-app é um deployment fantasma que pode ser removido com segurança.

| Item      | Valor                                          |
|-----------|------------------------------------------------|
| Diretório | /var/www/vozpro-app/                           |
| Conteúdo  | .env, ecosystem.config.js, .next/              |
| PM2       | NAO registrado (inativo)                       |
| Nginx     | NENHUM server block aponta para este diretório |
| Status    | OBFUSOLETO - pode ser removido                 |

Tabela 4: vozpro-app - deployment obsoleto

## 2. Estrutura de Arquivos no Oracle

### 2.1 PHP Backend (/var/www/omnivoice/)

Este diretorio contem todos os endpoints PHP da API de audio. O Nginx serve estes arquivos via PHP-FPM 8.3 para os dominios api.cvmnews.com.br e api.sorteiomax.com.br. Cada arquivo tem uma funcao especifica no pipeline de geracao de voz.

| Arquivo                | Funcao                                        | Metodo          |
|------------------------|-----------------------------------------------|-----------------|
| generate-omnivoice.php | Geracao TTS principal (PHP direto do browser) | native-generate |
| tunnel-generate.php    | Proxy PHP para geracao nativa via tunnel      | native-generate |
| generate-direct.php    | Geracao direta alternativa                    | Gradio (antigo) |
| generate.php           | Geracao original via Vercel                   | Vercel          |
| config.php             | Configuracoes (API key, URLs, constantes)     | N/A             |
| get_tunnel.php         | Retorna URL do tunnel ativo                   | N/A             |
| tunnel-config.ini      | URL do tunnel (atualizada pelo cloudflared)   | N/A             |
| update_tunnel.php      | Recebe nova URL do tunnel do cloudflared      | N/A             |
| upload.php             | Upload de audio de referencia                 | N/A             |
| health.php             | Health check do sistema                       | N/A             |

Tabela 5: Arquivos PHP do backend

### 2.2 Next.js Frontend (/home/ubuntu/omnivoice/)

O frontend Next.js esta em /home/ubuntu/omnivoice/ e roda como standalone server via PM2 na porta 3001. O build esta em .next/standalone/server.js. O .env contem as variaveis de ambiente incluindo DATABASE\_URL, NEXTAUTH\_URL, AUDIO\_SERVER\_URL e a API key.

### 2.3 Arquivo .env (variaveis de ambiente)

| Variavel                     | Valor                                               |
|------------------------------|-----------------------------------------------------|
| DATABASE_URL                 | postgresql://omnivoice:***@127.0.0.1:5432/omnivoice |
| AUDIO_SERVER_URL             | https://api.cvmnews.com.br                          |
| NEXT_PUBLIC_AUDIO_SERVER_URL | https://api.cvmnews.com.br                          |
| NEXTAUTH_URL                 | https://vozproof.com.br                             |

|                      |                                   |
|----------------------|-----------------------------------|
| ADMIN_PASSWORD       | VozPro@2026                       |
| JWT_SECRET           | vozpro-production-jwt-secret-2026 |
| AUDIO_SERVER_API_KEY | omnivoice_api_key_2026_secure     |
| PORT                 | 3001                              |

Tabela 6: Variaveis de ambiente do Next.js

### 3. Fluxo de Geracao de Audio (Apos Migracao)

A migracao de 02/06/2026 unificou o sistema para usar exclusivamente o endpoint /api/native-generate, eliminando a dependencia do Gradio API que era a fonte de lentidao e instabilidade. Antes da migracao, o generate-omnivoice.php usava o Gradio (3 etapas complexas), enquanto o tunnel-generate.php ja usava native-generate. Agora ambos usam o mesmo metodo.

#### 3.1 Fluxo Atual (native-generate)

1. Browser do usuario envia JSON POST para api.cvmnews.com.br/generate-omnivoice.php
2. PHP valida token HMAC e processa input (strip SSML, clean text, clamp speed 0.5-1.5)
3. PHP descobre tunnel URL via tunnel-config.ini ou get\_tunnel.php
4. Se modo clone: PHP baixa audio de referencia, converte para base64
5. PHP monta payload JSON e envia POST para tunnel/api/native-generate
6. GPU local recebe JSON, executa OmniVoice, retorna audio como base64
7. PHP recebe resposta, adiciona silence pad (750ms), converte para data URI
8. PHP retorna data URI (audio/wav;base64,...) para o browser

#### 3.2 Antes vs Depois da Migracao

| Aspecto          | Antes (Gradio)                   | Depois (native-generate)      |
|------------------|----------------------------------|-------------------------------|
| Etapas           | 3 (upload + submit + SSE stream) | 1 (JSON POST direto)          |
| Protocolo        | Gradio API (multipart + SSE)     | REST JSON (POST + response)   |
| Tempo tipico     | 15-45s (variavel)                | 5-15s (estavel)               |
| Ponto de falha   | 3 (upload, submit, stream)       | 1 (POST unico)                |
| Retry necessario | Frequente (timeout, 404)         | Raro (1 retry basta)          |
| Download audio   | Separado via URL do Gradio       | Embutido no response (base64) |
| Complexidade PHP | 856 linhas                       | 512 linhas (-40%)             |

Tabela 7: Comparacao antes/depois da migracao

## 4. Migracao Realizada (02/06/2026)

### 4.1 Resumo da Migracao

A migracao consistiu em reescrever o arquivo generate-omnivoice.php para usar o endpoint /api/native-generate em vez da API Gradio. Todas as funcionalidades foram preservadas: validacao HMAC, debug logging, queue monitor, SSML strip, clean text, WAV silence pad, retry logic e speed clamping. O arquivo foi reduzido de 856 para 512 linhas (-40% de complexidade).

### 4.2 Backups Criados

| Backup                | Caminho                                                      | Tipo             |
|-----------------------|--------------------------------------------------------------|------------------|
| Backup completo PHP   | /var/www/omnivoice-backup-20250602/                          | cp -a (completo) |
| Backup Gradio do PHP  | /var/www/omnivoice/generate-omnivoice.php.gradio-backup-*    | cp individual    |
| Backup Next.js source | /home/ubuntu/omnivoice-backup-20250602/src/                  | cp -a            |
| Backup .env           | /home/ubuntu/omnivoice-backup-20250602/.env.backup           | cp individual    |
| Backup next.config.ts | /home/ubuntu/omnivoice-backup-20250602/next.config.ts.backup | cp individual    |
| Backup package.json   | /home/ubuntu/omnivoice-backup-20250602/package.json.backup   | cp individual    |

Tabela 8: Backups criados antes da migracao

### 4.3 Features Preservadas na Migracao

| Feature              | Descricao                                                   |
|----------------------|-------------------------------------------------------------|
| Validacao HMAC token | Verifica assinatura timestamp+HMAC com API_KEY              |
| Debug logging        | Steps com timing para diagnostico de problemas              |
| Queue monitor        | JSON em /tmp/vp_queue_monitor.json                          |
| SSML strip           | Remove tags HTML/XML do texto de entrada                    |
| Clean text           | Remove caracteres de controle invisiveis                    |
| WAV silence pad      | Adiciona 750ms de silencio no final (protege ultima silaba) |
| Retry logic          | 3 tentativas com backoff exponencial                        |

|                  |                                                             |
|------------------|-------------------------------------------------------------|
| Speed clamping   | Limita speed entre 0.5 e 1.5 (range oficial OmniVoice)      |
| 3 modos          | clone (ref audio), design (instruct), auto (modelo escolhe) |
| 3 modos (antigo) | clone (_clone_fn), design (_design_fn), auto (_design_fn)   |

Tabela 9: Features preservadas na migracao

## 4.4 Testes Realizados

| Teste                         | Resultado                                  |
|-------------------------------|--------------------------------------------|
| PHP syntax check              | No syntax errors detected                  |
| Endpoint native-generate      | Sucesso: 2.04s audio em 0.69s (130KB)      |
| Referencias Gradio no PHP     | Zero em codigo produtivo (1 no comentario) |
| Referencias hf.space nos PHPs | Zero                                       |
| Backup integridade            | Arquivos presentes e acessiveis            |

Tabela 10: Resultados dos testes pos-migracao

## 5. Sistema de Tunnel

O tunnel Cloudflare e o componente que conecta o servidor Oracle a GPU local. O cloudflared roda na maquina local do usuario e cria um tunnel HTTPS que expoe o servidor Python da GPU na internet com uma URL aleatoria do tipo \*.trycloudflare.com. O Oracle descobre esta URL dinamicamente e a usa para enviar requisicoes de geracao.

### 5.1 Fluxo de Descoberta do Tunnel

1. O script start\_tunnel.ps1 na maquina local inicia o cloudflared
2. O cloudflared cria tunnel e gera URL aleatoria (ex: improved-mostly-accommodation-yacht.trycloudflare.com)
3. O script chama update\_tunnel.php no Oracle para registrar a URL
4. O update\_tunnel.php salva a URL em tunnel-config.ini
5. O generate-omnivoice.php le tunnel-config.ini para descobrir a URL ativa
6. Fallback: se tunnel-config.ini nao existir, usa get\_tunnel.php ou HF\_SPACE\_URL

### 5.2 Configuracao Atual do Tunnel

| Item | Valor |
|------|-------|
|------|-------|



|                   |                                                               |
|-------------------|---------------------------------------------------------------|
| tunnel_url        | https://improved-mostly-accommodation-yacht.trycloudflare.com |
| updated_at        | 2026-06-01 10:40:29                                           |
| Arquivo config    | /var/www/omnivoice/tunnel-config.ini                          |
| Script de update  | /var/www/omnivoice/update_tunnel.php                          |
| Script de leitura | /var/www/omnivoice/get_tunnel.php                             |

Tabela 11: Configuracao atual do tunnel

## 6. Procedimento de Rollback

Se a migracao causar qualquer problema, o rollback e simples e rapido. Existem dois niveis de rollback: o individual (restaurar apenas o PHP) e o completo (restaurar tudo do backup). Ambos sao nao-destrutivos, ou seja, o backup nunca e sobrescrito.

### 6.1 Rollback Individual (PHP apenas)

Este e o rollback recomendado para a maioria dos problemas. Restaura apenas o generate-omnivoice.php para a versao Gradio anterior. Executar via SSH no Oracle:

```
sudo cp /var/www/omnivoice/generate-omnivoice.php.gradio-backup-* \  
/var/www/omnivoice/generate-omnivoice.php  
sudo chown www-data:www-data /var/www/omnivoice/generate-omnivoice.php
```

### 6.2 Rollback Completo

Restaura todos os arquivos do backup completo. Usar em caso de problema mais grave:

```
sudo cp -a /var/www/omnivoice-backup-20250602/* /var/www/omnivoice/  
sudo cp -a /home/ubuntu/omnivoice-backup-20250602/src/*  
/home/ubuntu/omnivoice/src/  
sudo cp /home/ubuntu/omnivoice-backup-20250602/.env.backup  
/home/ubuntu/omnivoice/.env  
pm2 restart omnivoice
```

## 7. Arquivos Pendentes de Limpeza

Apos a estabilizacao da migracao, alguns arquivos e diretorios podem ser removidos com seguranca para manter o servidor limpo. Nenhum destes itens esta em producao ativa.

| Item                | Caminho              | Motivo                                 | Risco |
|---------------------|----------------------|----------------------------------------|-------|
| vozpro-app          | /var/www/vozpro-app/ | Deployment obsoleto, nao roda no PM2   | Baixo |
| HF_SPACE_URL        | config.php (linha)   | URL antiga do HF Space, nao mais usada | Baixo |
| generate.php        | /var/www/omnivoice/  | Geracao via Vercel (nao mais usado)    | Medio |
| generate-direct.php | /var/www/omnivoice/  | Ainda usa Gradio                       | Medio |

|                    |                         |                                    |       |
|--------------------|-------------------------|------------------------------------|-------|
| generate_local.php | /var/www/omnivoice/     | Local testing, nao produtivo       | Baixo |
| .next.bak.*        | /home/ubuntu/omnivoice/ | Multiplos backups de build (.next) | Baixo |
| .next.broken-*     | /home/ubuntu/omnivoice/ | Builds quebrados                   | Baixo |

Tabela 12: Arquivos passivos de limpeza

Recomendacao: aguardar 7 dias apos a migracao antes de remover qualquer arquivo. Se nao houver problemas, remover com backup previo.

## 8. VozPro vs OmniVoice: Nomenclatura

A nomenclatura do sistema pode causar confusao porque o nome do produto (VozPro) e diferente do nome do codigo (omnivoice). Aqui esta o mapeamento completo para evitar ambiguidade:

| Conceito         | Nome             | Onde esta                              |
|------------------|------------------|----------------------------------------|
| Produto/Marca    | VozPro           | vozproof.com.br, vozpro.cvmnews.com.br |
| Modelo TTS       | OmniVoice        | k2-fa/OmniVoice (HuggingFace)          |
| Frontend Next.js | omnivoice (PM2)  | /home/ubuntu/omnivoice/                |
| PHP Backend      | omnivoice        | /var/www/omnivoice/                    |
| Banco de dados   | omnivoice        | PostgreSQL: omnivoice@localhost        |
| GPU local        | omnivoice_gpu.py | Maquina local do usuario               |

Tabela 13: Mapeamento de nomenclatura

Resposta curta: o sub-dominio vozpro.cvmnews.com.br ainda existe no Nginx e faz proxy para o mesmo Next.js (porta 3001). Porem, o diretorio /var/www/vozpro-app/ e um deployment antigo que nao esta mais ativo. Todo o codigo atual esta em /home/ubuntu/omnivoice/ e /var/www/omnivoice/.